Processamento de Linguagem Natural

Resolução das Tarefas TC.19 e PC.19

Tarefa TC.19

Fontes de entrada em PLN e seus desafios técnicos

Desafios por Fonte de Dados (Parte 1)



(a) Língua Falada

Aplicação: Assistentes virtuais (ex: Alexa).

Dificuldades: Ruído de fundo afeta a transcrição (ASR). Variações de sotaque, velocidade da fala e entonação. Ambiguidade acústica (palavras homófonas como "cela" e "sela").



(b) Web Scraping

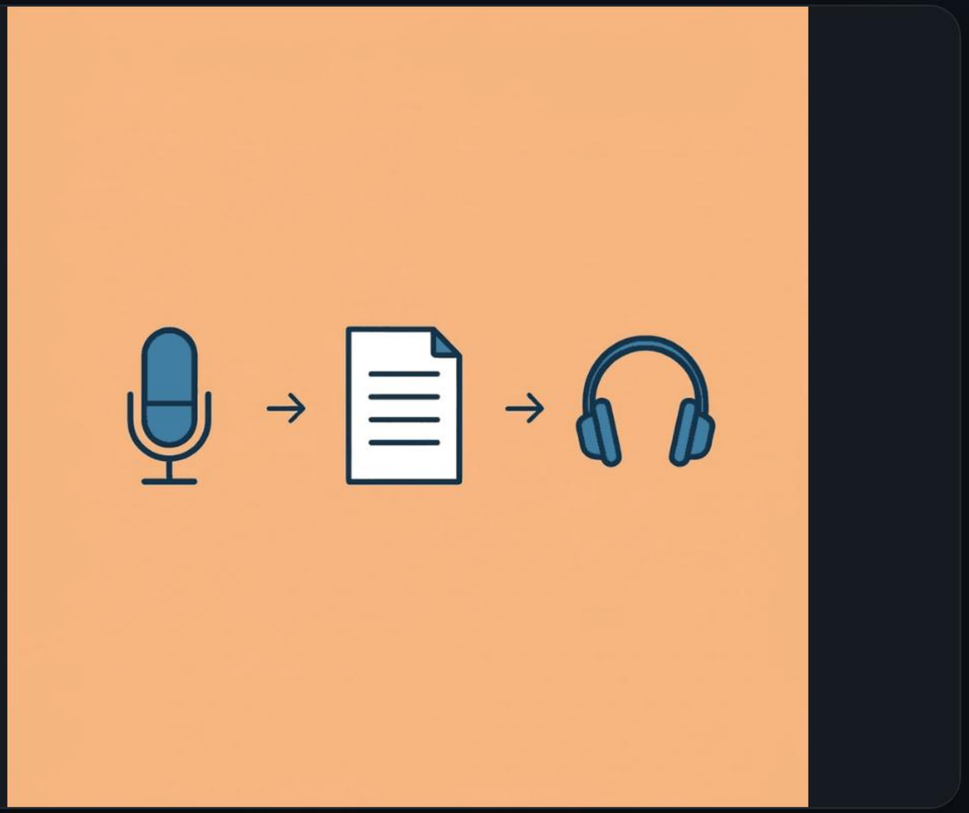
Aplicação: Agregadores de notícias; monitoramento de mercado.

Dificuldades: HTML desestruturado, tags variáveis, anúncios misturados ao texto útil. Dificuldade de limpeza (boilerplate removal). Mudanças frequentes no layout dos sites que quebram os extratores.

Desafios: Interação Direta

(c) Interação Escrita (Chatbots)

- **Aplicações:** Atendimento ao cliente automatizado (ex: WhatsApp, portais).
- **Erros ortográficos:** Usuários digitam com pressa, sem acentos, com abreviações (ex: "vc", "tb").
- **Linguagem informal:** Uso de gírias, emojis e ironia que dificultam a análise semântica.
- **Contexto:** Dificuldade do bot em manter o histórico da conversa e resolver anáforas (ex: "ele quem?").



Desafios: Tradução Automática

(d) Saída de Tradutores

- **Aplicações:** Pipeline multilingue onde o texto é traduzido antes da análise de sentimento ou extração de entidades.
- **Perda de nuance:** Traduções literais podem destruir expressões idiomáticas.
- **Erros de sintaxe:** A ordem das palavras traduzidas pode ficar antinatural, prejudicando parsers subsequentes (ex: POS tagging).
- **Propagação de erros:** Um erro inicial da tradução prejudica toda a pipeline de PLN (cascading errors).



Tarefa PC.19

Demonstração de Treebanks em Português

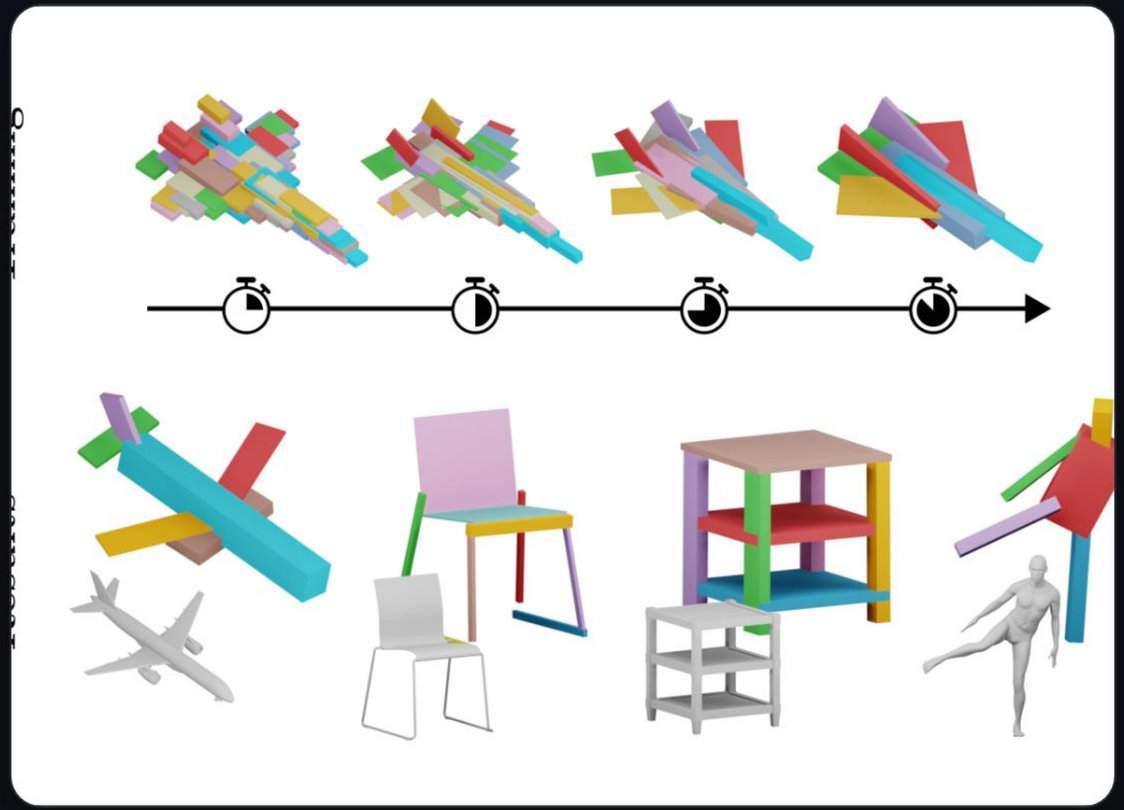
Treebanks da Língua Portuguesa

Um **Treebank** é um corpus de texto em que cada sentença foi anotada com uma estrutura sintática (muitas vezes em forma de árvore).

- Essenciais para treinar parsers sintáticos.
- Incluem anotações de Part-of-Speech (POS) e dependências.

Nesta tarefa, utilizaremos dois importantes Treebanks através da biblioteca NLTK:

- **Mac-Morpho** (Focado em anotação morfossintática/POS)
- **Floresta Sintá(c)tica** (Árvores sintáticas profundas)



1. Instalação e Setup

O primeiro passo é garantir que a biblioteca NLTK está instalada e baixar os pacotes dos corpora necessários.

```
# Instalação do NLTK (via terminal ou célula do Jupyter) !pip install nltk import nltk # Download dos pacotes específicos para a tarefa nltk.download('mac_morpho') nltk.download('floresta') nltk.download('punkt')
```

O código completo e executável está disponível no arquivo .ipynb anexado.

2. Utilizando o Mac-Morpho

O *Mac-Morpho* possui mais de um milhão de palavras de textos jornalísticos brasileiros (Folha de São Paulo) com anotações de categorias gramaticais (POS).

```
from nltk.corpus import mac_morpho # Acessando as sentenças já anotadas com POS tags sentencas_anotadas
= mac_morpho.tagged_sents() # Exibindo a primeira sentença print(sentencas_anotadas[0]) # Saída
esperada: # [('Jersei', 'N'), ('atinge', 'V'), ('média', 'N'), ... ]
```

3. Utilizando a Floresta Sintá(c)tica

A *Floresta Sintá(c)tica* é um treebank que anota a estrutura sintática de frases do português de Portugal e do Brasil.

```
from nltk.corpus import floresta # Acessando as estruturas de árvore (parsed sentences) arvores =
floresta.parsed_sents() # Acessando as palavras e suas tags (formato universal) palavras_anotadas =
floresta.tagged_words(tagset='universal') # Exibindo algumas palavras anotadas
print(palavras_anotadas[:5]) # Saída: [('Um', 'DET'), ('revivalismo', 'NOUN'), ...]
```

Concluído

As resoluções práticas (PC.19) estão no Notebook fornecido em anexo.

Tarefa 01 - Processamento de Linguagem Natural

Image Sources



https://www.bland.ai/_next/image?url=https%3A%2F%2Fcdn.sanity.io%2Fimages%2Ftmmoa80b%2Fproduction%2F88f7589f8b928951c9dd766fa733c709a32aec2c-1024x1024.png%3Fw%3D1920&w=3840&q=75

Source: www.bland.ai



https://www.slideegg.com/image/catalog/50178-artificial-intelligence-ppt-presentation.png

Source: www.slideegg.com



https://graphics.rwth-aachen.de/media/paper_images/None/representative_image.jpg

Source: www.graphics.rwth-aachen.de